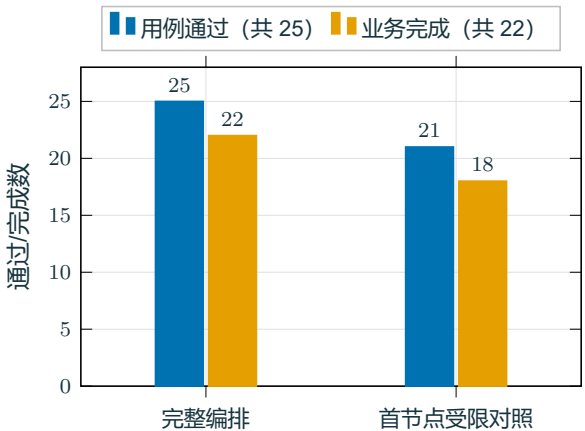
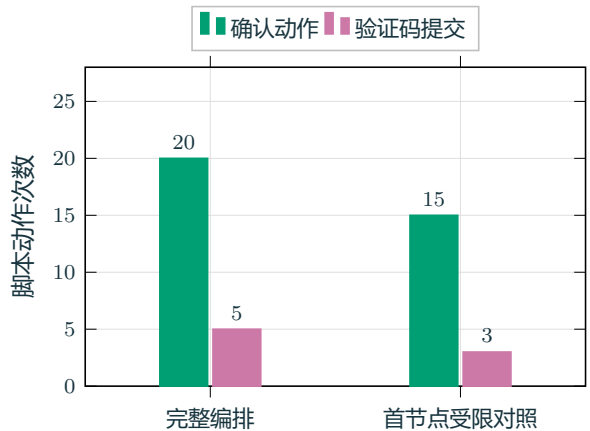
F6 固定离线任务：完成情况与交互负担

2026-10-21；规则规划；每组 25 用例，业务目标 22 个；无真实模型或人类被试





对照只执行首节点，因此天然缺少复合任务覆盖；较少确认不代表体验更好。安全探针 10/10 通过，不等于未知攻击安全证明。任务时延完整组 p50/p95：405.289/907.988 ms，对照组 449.081/700.488 ms。每任务一次运行，排除真人等待与模型推理；数据源：evals/results/offline-20261021.json。